chatTest — Critique Impeccable completa

Nov 5, 2026 · @GIA

Metodo

La demo chatTest prende **19/40**: concetti forti, esecuzione visiva da rifare. Il test segue il comando `critique` della skill Impeccable (v4.8.0, repo pubblico pbakaus/impeccable), applicato al sorgente Flutter in `lib/` (14 file .dart, 3.127 righe).

- **Valutazione A, revisione di design:** euristiche di Nielsen, carico cognitivo, percorso emotivo, persona. Eseguita da un agente isolato.
- **Valutazione B, controlli meccanici:** contrasto WCAG calcolato, regole "craft floor" e "operate" di Impeccable, token, motion, stati, RTL. Eseguita da un secondo agente isolato, senza vedere A.
- **Superficie:** modalità Operate (UI di prodotto), con l'obiettivo aggiuntivo di reggere lo sguardo di un design director in portfolio.

Limiti: il detector ufficiale (`impeccable detect`) non è stato eseguito perché è un binario da scaricare, e la demo Flutter disegna su canvas, quindi non c'è DOM da analizzare. Flutter non è installato nel sandbox: nessun rendering, tutti i numeri vengono dal codice. Snapshot e trend non salvati per lo stesso motivo; è il primo run su questo target.

Punteggio euristiche

Totale **19/40**, fascia "scarso" al limite alto: tre euristiche su dieci prendono 1, nessuna prende 4.

#	Euristica	Voto (0–4)	Problema chiave
1	Visibilità dello stato	3	Gli step in streaming funzionano; approva/rifiuta mostrano solo uno snackbar e il checkpoint resta attivo
2	Linguaggio del mondo reale	2	Al cliente arrivano "Hallucination Safety Framework", "Tier 2: Interpretive Analysis", "Show ML reasoning", "Streaming Validation"

#	Euristica	Voto (0–4)	Problema chiave
3	Controllo e libertà	1	Nessun annulla durante lo streaming, nessun reset, nessun undo; Approve premibile più volte
4	Coerenza e standard	2	Emoji mescolate a Material Icons; tre stili di bottone; link `Colors.blue[700]` fuori palette
5	Prevenzione errori	2	Approve bloccato dalla checkbox, ma Decline non richiede motivo; "Select reason…" è selezionabile
6	Riconoscimento, non memoria	3	Le 4 azioni rapide sono sempre visibili
7	Flessibilità ed efficienza	1	Solo Invio per inviare; toggle EN/AR come `GestureDetector`, irraggiungibile da tastiera; nessuna scorciatoia per l'RM
8	Estetica minimalista	2	Banner del framework sempre visibile; la risposta dello scenario 2 impila circa 8 blocchi
9	Recupero dagli errori	2	Il Data Quality Alert è buono, ma "Report Issue" non fa nulla e manca un percorso di errore o bassa confidenza
10	Aiuto e documentazione	1	Il benvenuto non spiega che ci sono 4 scenari scriptati

Specificità e cosa funziona

Il pensiero appartiene a questo prodotto, il look potrebbe essere di qualunque chat.

Specifico del prodotto. I tier 1/2/3 corrispondono a comportamenti (rispondere, qualificare, passare a un umano). `UncertaintyData` divide il totale in confermato, stimato e incerto. Il checkpoint è vincolato a un'attestazione. Nessun template di chat generico ha queste cose.

Non specifico. `app_theme.dart` (righe 84–121) è la palette degli alert Bootstrap (#28a745, #ffc107, #dc3545, #cfe2ff; il commento dice "pastel style like HTML"). Emoji al posto delle icone, header a gradiente, ombra da telefono fluttuante (opacità 0,3, blur 60), barra d'accento da 4px e alone luminoso sui pallini semaforo. Il craft floor di Impeccable rifiuta ognuna di queste scelte.

Identità di una banca reale. Nome "Commercial Bank AI Assistant", bordeaux del brand e ID sessione "CBQ-2026-0208-4521". In un portfolio pubblico è un rischio di marchio e di impersonificazione.

Cosa funziona:

1. **Tassonomia della fiducia** e scomposizione verificabile: 38.445 confermati + 4.285 stimati + 2.500 incerti = 45.230. È la storia da portfolio.
2. **RTL curato:** coda della bolla con `BorderRadiusDirectional`, numeri e barra di avanzamento bloccati in LTR, tema arabo con Noto Sans Arabic.
3. **Dettagli giusti:** Approve bloccato dalla checkbox, ragionamento ML dietro progressive disclosure con marcatori ⚠/✓, step in streaming con semantica `liveRegion`.

Problemi prioritari

Quattro problemi P1 e uno P2; i P1 sono quelli che contano per il portfolio.

P1 — Linguaggio visivo preso in prestito e brand reale

- **Perché conta:** un design director legge colori Bootstrap più emoji come prototipo assemblato, non progettato. L'identità CBQ è un rischio legale.
- **Fix:** banca fittizia e palette sobria propria; un solo set di icone (Material Symbols); via barra d'accento, alone, gradienti e ombra fluttuante; dicitura "Concept, not affiliated".
- **Comandi Impeccable:** `polish`, poi `document`.

P1 — L'apparato di sicurezza seppellisce la risposta

- **Perché conta:** la risposta, motivo per cui si apre la chat, non è il centro visivo. "99%" è 18px bold (`confidence_indicator.dart:436`), la risposta 14px.
- **Fix:** cifra della risposta 24–28px semibold con numeri tabulari; confidenza in un solo chip espandibile (oggi è codificata 5 volte: pallini, barra, %, colore, etichetta); fonti in una riga ("Core Banking · 2 min fa"); banner spostato in "About this demo".

- **Comandi Impeccable:** `distill`, `layout`.

P1 — Il checkpoint di accountability è un timbro e non lascia traccia

- **Perché conta:** attestazione generica, Decline senza motivo, Approve ripetibile, nessuna decisione registrata. Contraddice la tesi del PoC. Il ragionamento espone inoltre "Recently married" e "87% converted to mortgage": tema etico.
- **Fix:** motivo obbligatorio sul rifiuto; dopo la decisione il checkpoint si chiude in una ricevuta di audit inline (chi, quando, cosa, ID sessione); attestazione con gli elementi specifici verificati; inferenze sensibili marcate come tali.
- **Comandi Impeccable:** `harden`, `clarify`.

P1 — Cliente e staff nello stesso schermo

- **Perché conta:** "RM Tips" sta accanto a "Balance" in una chat cliente, e l'header parla di allucinazioni al cliente, erodendo fiducia.
- **Fix:** switch di ruolo Cliente / Relationship Manager nell'header, con linguaggio separato; testo cliente semplice, per esempio "Verificato sui dati del tuo conto".
- **Comando Impeccable:** `clarify`.

P2 — Bilingue e accessibilità incompleti

- **Perché conta:** utenti arabi, da tastiera e da screen reader incontrano testo non tradotto, colori illeggibili e controlli irraggiungibili.
- **Fix:** tradurre le ~30 stringhe solo inglesi, correggere le 18 coppie di contrasto, attivare i pattern a righe già scritti per i segmenti di incertezza, portare tutto a 12px minimo. Dettagli nella sezione dei controlli meccanici.
- **Comandi Impeccable:** `audit`, `harden`.

Carico cognitivo e percorso emotivo

Il carico è alto: 5 controlli su 8 falliscono, e il percorso emotivo alterna allarme e celebrazione senza mai rassicurare.

Controlli di carico cognitivo falliti

- **Un solo focus:** il banner a 5 voci (`_buildFrameworkBanner`) è sempre visibile e compete con la chat.

- **Raggruppamento:** la risposta dello scenario 2 mostra badge tier, risposta, avviso, confidenza, barra di certezza, 3 fonti, ragionamento e 3 bottoni.
- **Gerarchia visiva:** la risposta è testo 14px, "99%" è 18px bold. La meta-informazione supera la risposta.
- **Una cosa alla volta:** il checkpoint mostra il motivo di rifiuto accanto ad Approve prima che l'utente scelga di rifiutare.
- **Scelte minime:** tre punti di decisione superano le 4 opzioni.

Punto di decisione	Opzioni visibili
Checkpoint	1 checkbox, 6 voci del menu, 2 bottoni
Risposta scenario 2	7 elementi interattivi
Area di input	4 chip, campo di testo, Invia (6)

Percorso emotivo

- **Valle:** la domanda più semplice (saldo) costa circa 3,7 s di "Authenticating user credentials…". La sicurezza sembra teatro e rallenta la risposta.
- **Ansia senza sollievo:** lo scenario 2 mostra un avviso giallo ⚠ sui soldi dell'utente, ma tutti i bottoni che lo risolverebbero non fanno nulla.
- **Handoff come fallimento:** il badge Tier 3 usa il rosa "errore" ("Human Handoff Required"); il flusso finisce su un'emoji da 36px e due bottoni morti.
- **Finale:** uno snackbar verde celebrativo ("✓ Recommendation approved!") dopo una spinta a vendere un mutuo. La traccia di audit sparisce e nella conversazione nulla mostra che la decisione sia stata registrata.

Controlli meccanici

18 coppie di contrasto su 37 falliscono, ci sono 24 glifi usati come icone, nessuna gestione della tastiera e circa 30 stringhe solo in inglese.

Contrasto

Tutte le coppie neutre e dei tier passano: `textPrimary` su bianco 16,1:1; `textSecondary` 5,3–7,0:1; badge tier 7,1–8,3:1; bianco su bordeaux 9,3:1. Falliscono le coppie di stato.

Coppia	Rapporto	Soglia	Dove
Legenda "medium" su #F5F5F5	1,50:1	4,5	uncertainty_bar.dart:144
Glifo ⚠ su #F8F9FA	1,55:1	4,5	expandable_section.dart:128
Warning #ffc107 su bianco (rischio "medium")	1,63:1	4,5	customer_profile_card.dart:146
Step completato, verde su verde chiaro	2,41:1	4,5	streaming_indicator.dart:73
Toggle EN/AR inattivo, `white54`, 12px	2,64:1	4,5	chat_screen.dart:620
Legenda "high" su #F5F5F5	2,87:1	4,5	uncertainty_bar.dart:144
Glifo ✓ su #F8F9FA	2,97:1	4,5	expandable_section.dart:128
Verde #28a745 su bianco (Potential Value)	3,13:1	4,5	customer_profile_card.dart:96
Bianco su verde (bottone Approve)	3,13:1	4,5	accountability_checkpoint.dart:156
`blue[700]` su #E7F3FF (link fonte)	4,09:1	4,5	source_attribution.dart:77
`white70`, sottotitolo 11px	4,14:1	4,5	chat_screen.dart:592
Legenda "low" su #F5F5F5	4,15:1	4,5	uncertainty_bar.dart:144
Bordo checkpoint	1,22:1	3	accountability_checkpoint.dart
Bordo input #DEE2E6	1,30:1	3	app_theme.dart:137
Barra confidenza media vs traccia	1,37:1	3	confidence_indicator.dart
Icona warning	1,51:1	3	message_bubble.dart:186

Il testo da 11px compare 4 volte (chat_screen.dart:592 e :741, customer_profile_card.dart:154, accountability_checkpoint.dart:223), contro il minimo di 12px dichiarato nel tema. Il colore grey[300] previsto per Approve disabilitato non viene mai applicato: con `onPressed: null` Material 3 usa il suo stile di default.

Icone e superfici

- **Glifi come icone (24):** emoji 🛡️, 🔬, ⚖️, 👨‍⚖️ a 36px, 📞, 💬, 📄, ℹ️, ⚠️ dentro le stringhe; unicode ▶, ✓, ✗, ⚠. Material Icons usate altrove: due sistemi di icone.
- **Gradienti (4):** header (chat_screen:554), bottone invio (:855), banner del framework con hex inline (:650), card di handoff (human_handoff:27).
- **Bordi colorati oltre 1px:** accento da 4px sul lato iniziale della card di confidenza (confidence_indicator:103); 2px sotto il banner; 2px sui bottoni di handoff.
- **Alone senza offset:** pallino semaforo con ombra colorata a opacità 0,6, blur 8 (confidence_indicator:236).
- **Card annidate:** `CustomerProfileCard` con bordo e ombra dentro la bolla con ombra; pannelli di checkpoint, fonti, handoff e incertezza dentro la bolla; tutto dentro il contenitore con ombra a 0,30.
- **Pattern "hero metric":** "NN%" 18px bold + etichetta + semaforo + barra (confidence_indicator:134).

Ombra	Opacità	Blur	Offset
Contenitore principale (chat_screen:490)	0,30	60	(0, 20)
`cardShadow`	0,08	8	(0, 2)
Barra di input	0,04	8	(0, -2)
Bottoni azione	0,06	4	(0, 1)

Token

- **Colori hardcoded fuori dal tema:** 6 `Color(0x…)` e 37 `Colors.*` (23 bianco, 5 grigi, 2 `blue[700]`, 3 bianco trasparente); 14 chiamate a `withOpacity`, API deprecata.
- **Token inutilizzati (9):** `primaryBurgundyDark`, `info`, `infoBannerBg`, `infoBannerBorder`, `cardBackground`, `borderRadiusPill`, `backgroundGradient`, `containerShadow` (duplicato inline), `fontSizeTiny`.
- **Token duplicati:** `success` = `confidenceHigh`, `warning` = `confidenceMedium`, `danger` = `confidenceLow`, `tier1Bg` = `confidenceHighBg`, tre azzurri identici, più duplicati di raggio, font, gradiente e durata.
- **Raggi:** 10 valori diversi (2, 3, 4, 6, 8, 10, 12, 16, 20, 25), 17 usi letterali; 25 non è un token.
- **Padding:** 19 `EdgeInsets` letterali fuori dalla scala 8/12/16/25.

- **Font:** nessuna famiglia per il latino; `google_fonts` è usato solo per l'arabo, quindi l'interfaccia latina esce in Roboto di default.
- **Codice morto:** `HandoffExplanation` mai istanziato; `_DiagonalStripesPainter`, `_DottedPainter` e `_LegendPattern` definiti ma mai disegnati.

Motion

- **Durate:** 300 ms (bolla, espansione, scroll, step) e 800 ms (barra di confidenza), entrambe sopra i 150–250 ms consigliati; ritardi finti di 300 e 500 ms.
- **Entrata ripetuta:** ogni `MessageBubble` ha lo stesso slide (0,3) + fade (message_bubble:41).
- **Riduzione movimento:** mai rispettata; `disableAnimations` non compare.

Stati

- **Tastiera e hover:** zero `FocusNode`, `Focus`, `Shortcuts`, `onHover`, `MouseRegion`.
- **Gestori vuoti:** bottoni azione (message_bubble:273), bottoni di handoff (:250–251), link alle fonti (source_attribution:66).
- **Decline:** il menu del motivo non vincola il bottone.
- **Azioni rapide disabilitate:** solo opacità 0,5, nessuno stile disabilitato vero.
- **Mancanti:** stati di errore e vuoto; validazione del campo di testo.
- **Semantica:** 6 widget `Semantics`, tutti solo in inglese; le emoji non sono escluse e vengono lette dallo screen reader.

RTL e lingue

- **Stringhe:** `app_strings.dart` copre 75 righe, ma altri 41 ternari `isArabic ?` stanno fuori.
- **Solo inglese (circa 30):** 14 etichette di streaming, 4 etichette del profilo, gli snackbar, il titolo "Commercial Bank AI Assistant", "Show ML reasoning" (tradotto confrontando stringhe), tutte le etichette semantiche.
- **Direzione:** ▶ non si capovolge in RTL (expandable_section:83); gli altri 8 usi di API direzionali sono corretti.
- **Locale:** importo `QAR` formattato a mano; nessun locale passato a `MaterialApp`.
- **Conversazione mista:** cambiando lingua a metà, i messaggi precedenti restano nella lingua vecchia.

Persona, osservazioni e prossimi passi

Tre persona su tre incontrano un blocco nel flusso principale; il percorso di correzione proposto parte dal visivo e chiude con `polish`.

Segnali rossi per persona

- **Primo utilizzo (cliente):** il benvenuto non spiega i chip; il testo libero riceve una risposta precotta che parla di "hallucination safety features"; "Tier 2: Interpretive Analysis" non significa nulla; i bottoni di handoff non rispondono.
- **Accessibilità:** toggle lingua irraggiungibile da tastiera; segmenti di incertezza solo a colore; contrasti sotto soglia; etichette per screen reader in inglese anche in arabo; "CONFIDENCE SCORE" tutto maiuscolo.
- **RM esperto:** ogni richiesta costa 4 step di streaming (circa 3,7 s) senza salto; nessuna scorciatoia per approvare o rifiutare; decisioni non persistite, quindi nessuna coda o storico; cinque punti di ragionamento da riaprire ogni volta.

Osservazioni minori

- Saldo e spesa mensile valgono entrambi 45.230; il ±2.000 non torna con i 2.500 incerti.
- `explanation` viene passato a `HumanHandoff` ma mai mostrato.
- Larghezza massima della bolla al 75% dello schermo (message_bubble.dart:125), non del contenitore da 600px.
- `ExpandableSection` traduce il titolo confrontando stringhe.
- "Approve & Schedule": cosa si pianifica non è detto.
- Nessun modo per azzerare la conversazione.

Domande da farsi

- Se ogni risposta potesse portare un solo segnale di fiducia, quale sarebbe? Il resto può stare dietro un tocco?
- L'handoff umano è un fallimento o il momento migliore del prodotto?
- Dove vede il cliente che un umano è stato responsabile?
- Uno strumento per RM dovrebbe mostrare "recently married"?

Comandi Impeccable, in ordine

1. `document`: fissare il nuovo mondo visivo (banca fittizia, palette, tipografia, icone) in un DESIGN.md.
2. `distill`: risposta protagonista, confidenza in un chip, fonti in una riga, banner fuori dalla chat.

3. `layout`: scala di spaziature e raggi unica, niente card annidate, bolla legata al contenitore.
4. `typeset`: famiglia latina vera, scala 1,125–1,2, numeri tabulari, minimo 12px.
5. `clarify`: switch Cliente/RM e linguaggio separato, etichette dei tier in parole semplici.
6. `harden`: ricevuta di audit, motivo obbligatorio, gestori vuoti collegati, stati di errore e vuoto, traduzioni mancanti.
7. `audit`: contrasto, tastiera, semantica, riduzione del movimento.
8. `polish`: passaggio finale, poi nuovo `critique` per misurare il miglioramento.